

Restauration d'Images Dégradées par Filtrage de Wiener-Hunt

Résolution Analytique et Algorithmique de Problèmes Inverses Linéaires Mal Posés en Traitement d'Images 2D

Mohammed EL BARAKA

EMINES – School of Industrial Management
Université Mohammed VI Polytechnique (UM6P)
Février 2026

Résumé Exécutif : Ce travail présente une étude mathématique et expérimentale approfondie de la déconvolution d'images bruitées et floutées par l'approche de **Wiener-Hunt régularisée**. Face au caractère sévèrement mal posé de l'inversion directe au sens d'Hadamard, nous formalisons le problème dans le cadre variationnel des moindres carrés pénalisés de Tikhonov. Grâce à l'approximation circulante des opérateurs de convolution spatiale, nous démontrons la diagonalisation exacte du système par la Transformée de Fourier Discrète 2D (DFT), ramenant la complexité de résolution de $\mathcal{O}(N^6)$ à $\mathcal{O}(N^2 \log N)$. Une analyse comparative rigoureuse est menée sur deux scénarios physiques fondamentaux : un flou gaussien isotrope ($H(\nu) > 0$) et un flou de mouvement rectangulaire 7×7 comportant des zéros spectraux stricts. L'influence du paramètre de compromis λ , la sensibilité des métriques d'erreur ($L_1, L_2, L_\infty, \text{PSNR}, \text{SSIM}$), le choix des opérateurs régularisateurs (Identité, Gradient, Laplacien) et l'impact du fenêtrage de bord (**edge tapering**) sont systématiquement quantifiés.

Table des matières

1	Introduction et Contexte	2
2	Modélisation et Résolution du Problème Inverse	2
2.1	Le Modèle Direct de Dégradation Linéaire	2
2.2	Caractère Mal Posé au Sens d'Hadamard	3
2.3	Régularisation de Tikhonov et Critère de Wiener-Hunt	3
2.3.1	Dérivation Analytique du Minimiseur	3
2.4	Approximation Circulante et Diagonalisation par DFT 2D	4
2.5	Analyse des Noyaux de Régularisation Spatiale	5
3	Analyse Spectrale et Caractérisation des Dégradations	5
3.1	Analyse Fréquentielle des Images Observées	5
3.2	Étude Comparée des Réponses Impulsionnelles (PSF et OTF)	6
3.2.1	Analyse Mathématique du Flou Gaussien (Data1)	6
3.2.2	Analyse Mathématique du Flou Boîte / Mouvement (Data2)	7
4	Résultats Expérimentaux et Discussion	7
4.1	Dilemme Biais-Variance et Régimes de Régularisation	7
4.2	Optimisation Quantitative et Courbes en U	8
4.3	Concordance Multi-Métrique ($L_1, L_2, L_\infty, \text{PSNR}, \text{SSIM}$)	8

4.4 Comparaison des Opérateurs de Régularisation	9
4.5 Cartographies Spatiales des Erreurs Résiduelles	10
4.6 Phénomènes de Bord et Fenêtrage Cosinus (Edge Tapering)	10
5 Synthèse et Perspectives	10
5.1 Extensions et Méthodes Modernes	11
6 Conclusion	11

1 Introduction et Contexte

La dégradation d'images bidimensionnelles par flou optique et bruit électronique représente l'un des problèmes inverses linéaires les plus fondamentaux en traitement du signal et de l'image, en astronomie, en microscopie biomédicale et en vision par ordinateur.

Dans un système d'acquisition réel, la formation de l'image est soumise à des imperfections physiques incontournables : diffraction de l'ouverture optique, aberrations de lentilles, défauts de mise au point (**defocus**), mouvements relatifs entre la caméra et la scène, ainsi que le bruit thermique et quantique des capteurs CCD/CMOS.

L'objectif de la restauration d'image (ou **déconvolution**) est de reconstruire l'image originale non dégradée à partir de la seule observation bruitée et de la connaissance de la réponse impulsionnelle du système (Point Spread Function, notée PSF).

Cependant, la convolution spatiale agit intrinsèquement comme un filtre passe-bas qui atténue drastiquement les hautes fréquences spatiales. Par conséquent, l'inversion naïve (filtre inverse non régularisé) conduit à une explosion catastrophique du bruit, rendant le problème **sévèrement mal posé au sens d'Hadamard**.

Le présent rapport est structuré comme suit :

1. **Modélisation Mathématique & Résolution Variationnelle** : Dérivation analytique rigoureuse du critère de Tikhonov, gradient matriciel, équations normales, et diagonalisation unitaire par DFT 2D.
2. **Caractérisation Spectrale des Dégradations** : Analyse fréquentielle de l'énergie, comparaison des fonctions de transfert optiques (OTF) gaussienne vs sinus cardinal (zéros spectraux).
3. **Analyse du Compromis Biais-Variance & Optimisation de λ** : Démonstration de la convexité des courbes en U et étude de concordance multi-norme (L_1, L_2, L_∞ , PSNR, SSIM).
4. **Étude Comparative des Opérateurs Régularisateurs** : Évaluation des pénalités d'énergie (Tikhonov d'ordre 0), de gradient (ordre 1) et de courbure laplacienne (ordre 2).
5. **Phénomènes de Bord et Fenêtrage Cosinus (Edge Tapering)** : Atténuation des artefacts d'oscillations périodiques aux frontières.
6. **Discussion Approfondie & Perspectives Avancées** : Déconvolution aveugle, régularisation non quadratique par Variation Totale (TV) et méthodes variationnelles itératives (ADMM).

2 Modélisation et Résolution du Problème Inverse

2.1 Le Modèle Direct de Dégradation Linéaire

Soit $x^* \in \mathbb{R}^{N \times M}$ l'image originale discrète idéale, $h \in \mathbb{R}^{P \times Q}$ la réponse impulsionnelle spatiale (PSF) normalisée ($\sum_{n,m} h[n,m] = 1$), et $b \in \mathbb{R}^{N \times M}$ un bruit additif blanc gaussien à moyenne nulle et de variance σ_b^2 , indépendant de x^* :

$$y[n, m] = (h * x^*)[n, m] + b[n, m] = \sum_k \sum_l h[k, l] x^*[n - k, m - l] + b[n, m]$$

En vectorisant les images sous forme lexicographique (taille $K = NM$), le système s'écrit matriciellement :

$$\mathbf{y} = \mathbf{H}\mathbf{x}^* + \mathbf{b}$$

où $\mathbf{H} \in \mathbb{R}^{K \times K}$ est une matrice carrée structurée en **bloc-Toeplitz à blocs Toeplitz** (BTTB), représentant l'opérateur de convolution 2D avec conditions aux limites spatiales.

2.2 Caractère Mal Posé au Sens d'Hadamard

D'après Jacques Hadamard (1902), un problème inverse est dit **bien posé** si :

1. Une solution existe ;
2. La solution est unique ;
3. La solution dépend continûment des données d'observation (stabilité numérique).

Dans le cas de la convolution optique, les valeurs propres et valeurs singulières de $\mathbf{H}$ décroissent exponentiellement vers zéro pour les hautes fréquences spatiales ($\sigma_{i(\mathbf{H})} \rightarrow 0$). Si l'on applique l'inversion naïve des moindres carrés non régularisés ($\lambda = 0$) :

$$\hat{\mathbf{x}}_{\text{LS}} = \mathbf{H}^\dagger \mathbf{y} = \mathbf{x}^* + \mathbf{H}^{-1} \mathbf{b} = \mathbf{x}^* + \sum_{i=1}^K \frac{\mathbf{u}_i^T \mathbf{b}}{\sigma_i} \mathbf{v}_i$$

La variance totale de l'erreur d'estimation explose :

$$\mathbb{E}[\|\hat{\mathbf{x}}_{\text{LS}} - \mathbf{x}^*\|^2] = \sigma_b^2 \sum_{i=1}^K \frac{1}{\sigma_i^2} \rightarrow +\infty$$

Les composantes du bruit projetées sur les vecteurs singuliers associés aux petites valeurs singulières σ_i sont amplifiées par des facteurs gigantesques ($\frac{1}{\sigma_i}$), noyant totalement l'image dans un bruit à haute fréquence.

2.3 Régularisation de Tikhonov et Critère de Wiener-Hunt

Pour stabiliser l'inversion, nous introduisons une information a priori sur la régularité spatiale de l'image en résolvant le problème d'optimisation variationnel suivant :

$$\hat{\mathbf{x}}_\lambda = \arg \min_{\mathbf{x} \in \mathbb{R}^K} J(\mathbf{x}), \quad \text{avec} \quad J(\mathbf{x}) = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|_2^2 + \lambda \|\mathbf{D}\mathbf{x}\|_2^2$$

où :

- $\|\mathbf{y} - \mathbf{H}\mathbf{x}\|_2^2$ est le terme d'**attache aux données** (fidélité aux observations) ;
- $\|\mathbf{D}\mathbf{x}\|_2^2$ est le terme de **pénalisation de régularité** ;
- $\mathbf{D} \in \mathbb{R}^{K \times K}$ est un opérateur linéaire différentiel (gradient, laplacien) ou l'identité ;
- $\lambda > 0$ est le paramètre d'hyper-régularisation contrôlant le compromis fidélité/lissage.

2.3.1 Dérivation Analytique du Minimiseur

Développons la fonctionnelle quadratique $J(\mathbf{x})$:

$$J(\mathbf{x}) = (\mathbf{y} - \mathbf{H}\mathbf{x})^T (\mathbf{y} - \mathbf{H}\mathbf{x}) + \lambda (\mathbf{D}\mathbf{x})^T (\mathbf{D}\mathbf{x})$$

$$J(\mathbf{x}) = \mathbf{y}^T \mathbf{y} - 2\mathbf{y}^T \mathbf{H}\mathbf{x} + \mathbf{x}^T \mathbf{H}^T \mathbf{H}\mathbf{x} + \lambda \mathbf{x}^T \mathbf{D}^T \mathbf{D}\mathbf{x}$$

Calculons le gradient matriciel par rapport au vecteur $\mathbf{x}$:

$$\nabla_{\mathbf{x}} J(\mathbf{x}) = -2\mathbf{H}^T \mathbf{y} + 2\mathbf{H}^T \mathbf{H}\mathbf{x} + 2\lambda \mathbf{D}^T \mathbf{D}\mathbf{x}$$

En annulant le gradient pour trouver le point stationnaire ($\nabla_{\mathbf{x}} J(\mathbf{x}) = \mathbf{0}$) :

$$(\mathbf{H}^T \mathbf{H} + \lambda \mathbf{D}^T \mathbf{D}) \mathbf{x} = \mathbf{H}^T \mathbf{y}$$

La matrice hessienne $\nabla^2 J(\mathbf{x}) = 2(\mathbf{H}^T \mathbf{H} + \lambda \mathbf{D}^T \mathbf{D})$ est symétrique définie positive pour tout $\lambda > 0$ (dès lors que $\ker(\mathbf{H}) \cap \ker(\mathbf{D}) = \{\mathbf{0}\}$). La solution unique du problème est donc la solution exacte des équations normales :

$$\hat{\mathbf{x}}_{\lambda} = (\mathbf{H}^T \mathbf{H} + \lambda \mathbf{D}^T \mathbf{D})^{-1} \mathbf{H}^T \mathbf{y}$$

2.4 Approximation Circulante et Diagonalisation par DFT 2D

Pour une image de dimension 256×256 , la taille de la matrice $\mathbf{H}$ est $K = 65536$, et la matrice à inverser $(\mathbf{H}^T \mathbf{H} + \lambda \mathbf{D}^T \mathbf{D})$ possède une dimension de 65536×65536 (soit plus de 4,3 milliards d'éléments). Une inversion matricielle directe par élimination de Gauss ou factorisation de Cholesky nécessiterait $\mathcal{O}(K^3) = \mathcal{O}(N^6)$ opérations, soit de l'ordre de 10^{14} opérations arithmétiques, ce qui est numériquement prohibitif.

Théorème de Diagonalisation des Matrices Circulantes par DFT : Sous l'hypothèse de conditions aux limites périodiques (périodisation toroïdale de l'image), les matrices BTTB de convolution $\mathbf{H}$ et $\mathbf{D}$ sont exactement approximées par des matrices **bloc-circulantes à blocs circulants** (BCCB), notées $\tilde{\mathbf{H}}$ et $\tilde{\mathbf{D}}$. Toute matrice BCCB est diagonalisée par la matrice unitaire de Fourier 2D $\mathbf{F}$ ($\mathbf{F}^\dagger \mathbf{F} = \mathbf{I}$) :

$$\tilde{\mathbf{H}} = \mathbf{F}^\dagger \mathbf{\Lambda}_H \mathbf{F}, \quad \tilde{\mathbf{D}} = \mathbf{F}^\dagger \mathbf{\Lambda}_D \mathbf{F}$$

où $\mathbf{\Lambda}_H$ et $\mathbf{\Lambda}_D$ sont des matrices diagonales contenant respectivement les coefficients de la Transformée de Fourier 2D de la réponse impulsionnelle h et du noyau différentiel d .

En substituant cette décomposition spectrale dans les équations normales :

$$\hat{\mathbf{x}} = \left[(\mathbf{F}^\dagger \mathbf{\Lambda}_H \mathbf{F})^T (\mathbf{F}^\dagger \mathbf{\Lambda}_H \mathbf{F}) + \lambda (\mathbf{F}^\dagger \mathbf{\Lambda}_D \mathbf{F})^T (\mathbf{F}^\dagger \mathbf{\Lambda}_D \mathbf{F}) \right]^{-1} (\mathbf{F}^\dagger \mathbf{\Lambda}_H \mathbf{F})^T \mathbf{y}$$

Puisque $\mathbf{F}$ est unitaire ($\mathbf{F}^T = \mathbf{F}^*$, $\mathbf{F}^\dagger = \mathbf{F}^{-1}$) :

$$(\mathbf{F}^\dagger \mathbf{\Lambda}_H \mathbf{F})^T = \mathbf{F}^\dagger \mathbf{\Lambda}_H^* \mathbf{F}$$

$$\hat{\mathbf{x}} = [\mathbf{F}^\dagger (\mathbf{\Lambda}_H^* \mathbf{\Lambda}_H + \lambda \mathbf{\Lambda}_D^* \mathbf{\Lambda}_D) \mathbf{F}]^{-1} \mathbf{F}^\dagger \mathbf{\Lambda}_H^* \mathbf{F} \mathbf{y}$$

$$\hat{\mathbf{x}} = \mathbf{F}^\dagger (\mathbf{\Lambda}_H^* \mathbf{\Lambda}_H + \lambda \mathbf{\Lambda}_D^* \mathbf{\Lambda}_D)^{-1} \mathbf{\Lambda}_H^* \mathbf{F} \mathbf{y}$$

En passant dans l'espace des fréquences spatiales discrètes (ν_x, ν_y) avec $\hat{X}(\nu) = \mathcal{F}\{\hat{x}\}$ et $Y(\nu) = \mathcal{F}\{y\}$:

$$\hat{X}(\nu_x, \nu_y) = \frac{H^*(\nu_x, \nu_y)}{\underbrace{|H(\nu_x, \nu_y)|^2 + \lambda |D(\nu_x, \nu_y)|^2}_{G(\nu_x, \nu_y) \text{ [Filtre de Wiener-Hunt]}}} \cdot Y(\nu_x, \nu_y)$$

L'estimation finale $\hat{x}$ est ensuite calculée par la Transformée de Fourier Rapide Inverse (IFFT 2D) :

$$\hat{x}[n, m] = \mathcal{F}^{-1}\{G(\nu_x, \nu_y) \cdot Y(\nu_x, \nu_y)\}$$

Complexité computationnelle : Le calcul repose uniquement sur deux FFT 2D directes, une IFFT 2D et une division élément par élément de tableaux $N \times M$. La complexité passe de $\mathcal{O}(N^6)$ à $\mathcal{O}(N^2 \log N)$, permettant une restauration quasi-instantanée (inférieure à 10 millisecondes pour une image 256×256).

2.5 Analyse des Noyaux de Régularisation Spatiale

Le choix de l'opérateur différentiel D permet d'ajuster la pénalité spectrale :

Type d'Opérateur	Noyau Spatial $d[n, m]$	Réponse Fréquentielle $ D(\nu) ^2$	Propriété Physique
Identité (Tikhonov ordre 0)	$\begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix}$	$ D(\nu) ^2 = 1$ (constant)	Pénalise l'énergie globale $\sum x_n^2$, atténuation uniforme.
Gradient (Différences ordre 1)	$\begin{pmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{pmatrix}$	$4(\sin^2(\pi\nu_x) + \sin^2(\pi\nu_y))$	Pénalise les discontinuités locales, préserve les zones homogènes.
Laplacien (Courbure ordre 2)	$\begin{pmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{pmatrix}$	$16(\sin^2(\pi\nu_x) + \sin^2(\pi\nu_y))^2$	Pénalise les fortes courbures (dérivée 2nde), lissage très fort.

3 Analyse Spectrale et Caractérisation des Dégradations

3.1 Analyse Fréquentielle des Images Observées

Nous disposons de deux jeux de données de référence (256×256 pixels) :

- **Data1** : Image dégradée par un flou de type gaussien et un bruit additif.
- **Data2** : Image dégradée par un flou de type boîte uniforme 7×7 et un bruit additif.




Fig. 1. – Analyse spectrale 2D comparative : Images spatiales (haut) et spectres d'amplitude en échelle logarithmique $\log_{10}|Y(\nu) + 1|$ (bas). (a,d) Image originale non dégradée x^* , (b,e) Observation Data1 (flou gaussien isotrope), (c,f) Observation Data2 (flou rectangulaire avec stries d'annulation directionnelles).

Interprétation Physique des Spectres :

1. **Image de référence x^* (Fig. 1d)** : Le spectre présente une décroissance d'énergie typique des images naturelles en loi de puissance $\frac{1}{\|\nu\|^\alpha}$, avec une répartition équilibrée de l'énergie sur toutes les orientations.
2. **Observation Data1 (Fig. 1e)** : Le spectre montre une symétrie circulaire parfaite (**isotropie**). L'énergie s'atténue de manière continue et monotone vers les hautes fréquences, agissant comme un filtre passe-bas régulier.
3. **Observation Data2 (Fig. 1f)** : Le spectre présente une forte **anisotropie** caractérisée par des lignes sombres périodiques orthogonales aux axes du mouvement. Ces bandes d'extinction correspondent aux passages par zéro de la fonction de transfert.

3.2 Étude Comparée des Réponses Impulsionnelles (PSF et OTF)

La fonction de transfert optique (OTF) $H(\nu_x, \nu_y) = \mathcal{F}\{h[n, m]\}$ régit la transmission des fréquences spatiales à travers le système d'imagerie.




Fig. 2. – Caractérisation des filtres optiques : (a,b) Vues 3D des réponses impulsionnelles h_1 et h_2 . (c,d) Cartes 2D de la magnitude de l'OTF en échelle log. (e) Coupes fréquentielles 1D à $\nu_y = 0$, illustrant la stricte positivité pour Data1 ($H_1(\nu) > 0$) versus la présence de passages par zéro stricts pour Data2.

3.2.1 Analyse Mathématique du Flou Gaussien (Data1)

La PSF continue est donnée par une gaussienne bidimensionnelle :

$$h_1(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right) \iff H_1(\nu_x, \nu_y) = \exp(-2\pi^2\sigma^2(\nu_x^2 + \nu_y^2))$$

Propriété essentielle : La fonction $H_1(\nu)$ ne s'annule en aucun point fini ($H_1(\nu) > 0, \forall \nu$). Par conséquent, aucune composante harmonique n'est rigoureusement détruite ; elle est seulement exponentiellement atténuée. Le problème est mal conditionné mais ne présente pas de singularité stricte.

3.2.2 Analyse Mathématique du Flou Boîte / Mouvement (Data2)

La PSF spatiale de Data2 est une boîte uniforme 7×7 ($h_2[n, m] = \frac{1}{49}$ pour $|n|, |m| \leq 3$). Dans le domaine fréquentiel continu, cela correspond au produit de deux sinus cardinaux :

$$H_2(\nu_x, \nu_y) = \frac{\sin(7\pi\nu_x)}{7 \sin(\pi\nu_x)} \cdot \frac{\sin(7\pi\nu_y)}{7 \sin(\pi\nu_y)}$$

Propriété critique : La fonction $H_2(\nu)$ s'annule exactement pour toutes les fréquences :

$$\nu_x = \frac{k}{7}, \quad k \in \{\pm 1, \pm 2, \pm 3\}, \quad \nu_y = \frac{l}{7}, \quad l \in \{\pm 1, \pm 2, \pm 3\}$$

À ces fréquences nulles, toute l'information de l'image originale a été irrémédiablement effacée par le système optique. Lors de la déconvolution, la division par zéro provoquerait des singularités infinies ($\frac{1}{H_2}(\nu) \rightarrow \infty$). Le terme de régularisation $\lambda |D(\nu)|^2$ est indispensable pour borner le dénominateur et empêcher l'explosion des oscillations parasites (**phénomène de Gibbs**).

—

4 Résultats Expérimentaux et Discussion

4.1 Dilemme Biais-Variance et Régimes de Régularisation

Pour comprendre le comportement du filtre de Wiener-Hunt, nous décomposons mathématiquement l'erreur quadratique moyenne en fonction de λ :

$$\mathbb{E}[\|\hat{x}_\lambda - x^*\|^2] = \underbrace{\|(I - G_\lambda H)x^*\|_2^2}_{\text{Biais Quadratique } (\lambda \rightarrow \infty)} + \underbrace{\sigma_b^2 \text{Tr}(G_\lambda G_\lambda^T)}_{\text{Variance du Bruit } (\lambda \rightarrow 0)}$$




Fig. 3. – Galerie visuelle de reconstruction selon les régimes de régularisation λ sur Data1. De gauche à droite et de haut en bas : (a) Vérité terrain, (b) Observation floue, (c) Filtre inverse pur $\lambda = 0$ (explosion du bruit), (d,e) Sous-régularisation, (f) Restauration optimale $\lambda^* = 10^{-2}$ (compromis idéal, PSNR = 25.8 dB), (g,h) Sur-régularisation et lissage excessif.

L'exploration paramétrique révèle trois régimes distincts :

1. **Régime de sous-régularisation ($\lambda \rightarrow 0$)** : La variance domine. Le bruit est multiplié par des facteurs $\frac{1}{|H(\nu)|^2}$, générant un bruit granulaire à haute fréquence intense qui détruit toute lisibilité de l'image.
2. **Régime de sur-régularisation ($\lambda \gg 1$)** : Le biais domine. Le filtre supprime agressivement les hautes fréquences, lissant l'image au point d'effacer les contours et les textures fines.
3. **Régime optimal ($\lambda = \lambda^*$)** : Le compromis exact entre réduction du bruit et préservation de la netteté est atteint au minimum global de l'erreur.

4.2 Optimisation Quantitative et Courbes en U

Pour déterminer rigoureusement le paramètre λ^* optimal, nous traçons l'erreur relative normalisée $\Delta_2(\lambda) = \frac{\|\hat{x}_\lambda - x^*\|_2}{\|x^*\|_2}$ sur une échelle logarithmique couvrant 12 décades ($\lambda \in [10^{-8}, 10^4]$).




Fig. 4. – Courbes de régularisation en « U » pour Data1 (gaussien) et Data2 (boîte). La présence d'un minimum global unique et strictement convexe valide la théorie du compromis biais-variance.

Jeu de Données	λ^* Optimal	Erreur Δ_2	PSNR (dB)	SSIM	Gain PSNR
Data1 (Flou Gaussien)	1.00×10^{-2}	0.1324	25.84 dB	0.9120	+6.81 dB
Data2 (Flou Boîte 7×7)	3.98×10^{-2}	0.1581	24.31 dB	0.8745	+5.42 dB

4.3 Concorde Multi-Métrique (L_1, L_2, L_∞ , PSNR, SSIM)

Nous évaluons la robustesse de l'optimum vis-à-vis de différentes métriques mathématiques :

- Norme L_2 (Erreur quadratique relative) : $\Delta_2 = \frac{\|\hat{x} - x^*\|_2}{\|x^*\|_2}$
- Norme L_1 (Erreur absolue moyenne, robuste aux valeurs aberrantes) : $\Delta_1 = \frac{\|\hat{x} - x^*\|_1}{\|x^*\|_1}$
- Norme L_∞ (Écart maximal / erreur crête à crête) : $\Delta_\infty = \max_{\max} |\hat{x} - x^*| / \max |x^*|$
- Peak Signal-to-Noise Ratio (PSNR) : $\text{PSNR} = 10 \log_{10} \left(\frac{\max(x^*)^2}{\text{MSE}} \right)$
- Structural Similarity Index (SSIM) évaluant la cohérence structurelle locale.




Fig. 5. – Concordance multi-norme sur Data2 : Les minima des distances L_1, L_2, L_∞ et le maximum de PSNR coïncident au même ordre de grandeur ($\lambda \approx 10^{-2}$), prouvant la stabilité intrinsèque de la solution de Wiener-Hunt.

4.4 Comparaison des Opérateurs de Régularisation




Fig. 6. – Comparaison des opérateurs régularisateurs : (a) Courbes d'erreur $\Delta_2(\lambda)$ pour Tikhonov (Identité), Gradient (ordre 1) et Laplacien (ordre 2). (b,c,d) Reconstitutions optimales associées. L'opérateur Gradient offre le meilleur compromis netteté/lissage sur les contours nets.

- **Identité** ($D = I$) : L'atténuation étant indépendante de la fréquence, le filtre supprime uniformément toutes les fréquences, entraînant une perte de contraste global et un flou résiduel plus marqué ($\Delta_2 = 0.174$).
- **Gradient** ($D = D_1$) : Concentre la pénalité sur les très hautes fréquences tout en laissant passer les basses et moyennes fréquences porteuses des formes d'objets ($\Delta_2 = 0.132$).
- **Laplacien** ($D = D_2$) : Offre un lissage très efficace dans les zones planes mais pénalise plus sévèrement les transitions nettes (bords d'objets), créant un léger effet de halo ($\Delta_2 = 0.141$).

4.5 Cartographies Spatiales des Erreurs Résiduelles




Fig. 7. – Cartes d'erreur résiduelle spatiale $|x^* - \hat{x}|$: (a) Image observée, (b) Filtre inverse naïf $\lambda = 0$ (erreur distribuée uniformément sur toute la scène), (c) Restauration optimale Wiener-Hunt (résidus strictement localisés sur les contours à fort gradient).

La cartographie spatiale confirme que l'algorithme de Wiener-Hunt élimine quasiment la totalité du bruit dans les zones homogènes (fond, surfaces planes). Les seules erreurs résiduelles se concentrent sous forme de fines lignes le long des arêtes vives, ce qui est la signature inévitable d'un lissage linéaire quadratique.

4.6 Phénomènes de Bord et Fenêtrage Cosinus (Edge Tapering)

L'hypothèse sous-jacente à la décomposition par DFT est la périodicité 2D de l'image (raccordement toroïdal du bord gauche au bord droit et du bord haut au bord bas). Lorsque les intensités aux frontières opposées ne coïncident pas, cette discontinuité artificielle engendre une fuite spectrale à haute fréquence et des oscillations de bord (**ringing**).




Fig. 8. – Démonstration du fenêtrage de bord (**Edge Tapering**) : (a) Observation prétraitée avec transition cosinus lisse, (b) Déconvolution sans fenêtrage (présence d'ondulations parasites sur les bordures), (c) Déconvolution avec fenêtrage (suppression complète des artefacts de frontière).

L'application d'un masque de transition en cosinus sur une bordure de largeur proportionnelle à la PSF ($w \approx 2P$) élimine totalement ces artefacts sans altérer le contenu au centre de l'image.

5 Synthèse et Perspectives

Caractéristique	Data1 (Flou Gaussien)	Data2 (Flou Boîte 7×7)
Nature de la PSF	Gaussienne isotrope, $h[n, m] > 0$	Boîte rectangulaire 7×7 uniforme

Spectre $H(\nu)$	Strictement positif ($H(\nu) > 0$), pas de zéros	Passages par zéro stricts ($H(\nu_k) = 0$)
Conditionnement	Mal conditionné exponentiel, mais inversible	Singularité spectrale exacte (perte d'information)
λ^* Optimal (Gradient)	1.00×10^{-2}	3.98×10^{-2}
PSNR Final / SSIM	25.84 dB / 0.912	24.31 dB / 0.875
Complexité Calcul	$\mathcal{O}(N^2 \log N)$ via 2D FFT (< 10 ms)	$\mathcal{O}(N^2 \log N)$ via 2D FFT (< 10 ms)

5.1 Extensions et Méthodes Modernes

Pour dépasser les limitations intrinsèques du filtre linéaire de Wiener-Hunt :

1. **Régularisation par Variation Totale (TV)** : Remplacer la pénalité $L_2 (\|D\mathbf{x}\|_2^2)$ par une norme $L_1 (\|\nabla \mathbf{x}\|_1)$. La non-différentiabilité est résolue efficacement par l'algorithme des directions alternées (**ADMM**) ou l'algorithme de Chambolle-Pock, permettant une préservation parfaite des sauts de contraste (arêtes vives) sans effet de halo.
2. **Déconvolution Aveugle (Blind Deconvolution)** : Estimer conjointement l'image $\mathbf{x}$ et la réponse impulsionnelle inconnue $\mathbf{h}$ par minimisation alternée avec a priori de parcimonie spectrale.
3. **Méthodes Plug-and-Play (PnP-ADMM) et Priors Débruits Profonds (Deep Image Priors / Diffusion)** : Remplacer l'opérateur de régularisation explicite par un réseau de neurones débruiteur pré-entraîné, combinant la fidélité au modèle physique direct et la richesse des a priori statistiques appris sur de vastes corpus d'images.

6 Conclusion

Ce travail a permis de formaliser, d'implémenter et de valider expérimentalement la méthode de restauration d'images dégradées par filtrage régularisé de **Wiener-Hunt**.

Les principaux enseignements théoriques et numériques sont les suivants :

1. **Nécessité de la Régularisation** : L'inversion directe ($\lambda = 0$) est numériquement instable en raison de la décroissance des valeurs singulières de l'opérateur de convolution. L'introduction du terme de pénalité de Tikhonov transforme le problème mal posé en un problème strictement bien posé.
2. **Efficacité Computationnelle de l'Approche Fréquentielle** : L'approximation circulante permet de diagonaliser l'opérateur dans la base de Fourier, réduisant la complexité de $\mathcal{O}(N^6)$ à $\mathcal{O}(N^2 \log N)$ et autorisant des traitements en temps réel.
3. **Rôle Fondamental de la Structure de l'OTF** : La présence de zéros spectraux (cas de la boîte / mouvement) impose une régularisation plus forte pour contrôler les artefacts d'oscillations de Gibbs, confirmant que la limite ultime de restauration est dictée par la physique de la fonction de transfert.

— Fin du Rapport Technique —